

<인공지능 프로젝트>

GAN 기반 이상 검출 모델을 통한 신소재 개발 기간 단축 프로그램

B반 4조

오세현 강연지 김은영 우영빈 이동현 이정하

목차

1. 프로젝트 개요	3
1-1. 주제 소개	3
1-2. 추진 배경	4
1-3. 적용 기술	7
2. 시스템 구현	8
2-1. 데이터 수집 및 생성	8
2-2. 시스템 구조	10
2-3. 모델 소개	12
2-4. 모델 비교 선정	24
2-5. 프로젝트 산출물	27
3. 기대 효과 및 향후 개선 사항	30
3-1. 기대효과	30
3-2. 향후 개선 사항	31
4. 팀원 소개 및 상호평가	33
5. Reference	40

1. 프로젝트 개요

1-1. 주제 소개

본 조에서는 공정 조건 설정 - 미세조직 관찰 - 특성 분석 단계가 반복적으로 수행되는 신소재 개발/연구에서 미세조직 관찰 결과를 분석하여 소재의 특성을 미리 예측하는 인공지능 개발을 목표로 프로젝트를 진행하였다.

금번 개발한 프로그램의 설계는 아래 그림과 같다. 본 프로그램은 컴퓨터비전 인공지능 기술을 활용하여 소재의 미세조직 이미지를 분석한다. 사용자로부터 분석하고자 하는 이미지를 입력 받으면 강화상 및 결함, 기공과 같은 이미지 상의 특이점들을 소재의 바탕이 되는 기저상(matrix)으로부터 정밀하게 분리하고 특이점(강화상 또는 결함이나 기공) fixel 수를 전체 이미지의 fixel 수로 나누어 해당 미세조직의 분율을 정량적으로 도출할 수 있다. 추가적으로 원하는 특성치를 사용자가 선택하게 하여 해당 DB로부터 예상되는 특성치를 output 해주는 시스템이다.

프로그램 명칭은 GAN 기반 모델을 활용하였기 때문에 소재 분야 Research Engineer와 통합하여 GANgineer라고 명명하였다.

본 프로젝트에서 사용된 소재들의 미세조직 이미지는 모두 강화상(reinforcement)-기지상(matrix) 또는 기공(pore)-기지상(matrix)의 두 가지 조직으로 구성되어 있다. 따라서 기존에 의뢰 이미지 데이터로부터 이상조직 판별, 최종 제품 이미지에서의 결함 분석 용도로 사용되어 오던 AnoGAN 계열의 모델들을 사용하기로 하였다.

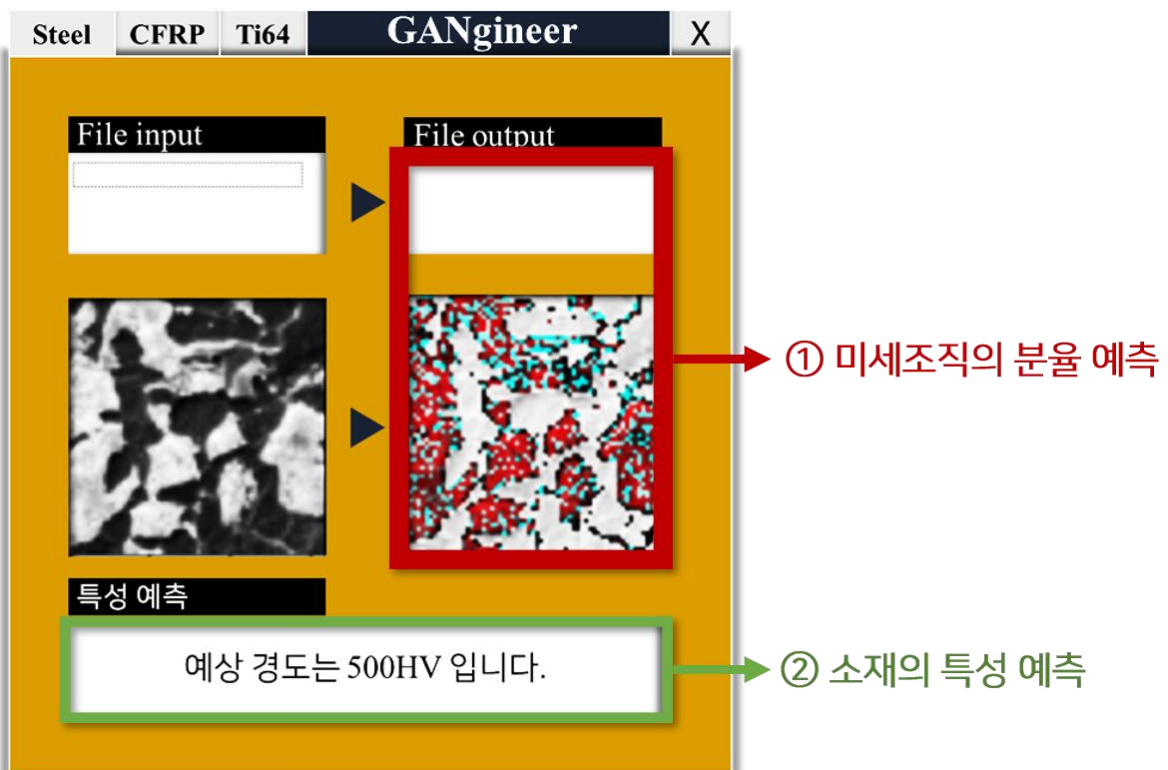


Figure 1. GANgineer 프로그램 설계 이미지 ① 미세조직 output 도시 ② 특성 예측 결과 도시

1-2. 추진 배경


본 프로젝트를 통해 복잡/다양한 소재 제조 프로세스와 특성 추출에 긴 시간이 소요되는 신소재 개발 기간을 단축시키고자 하였다. 또한 제조업 분야 기업들의 품질 향상에 근본이 되는 소재 개발 선진화와 더불어 국가 기반산업인 철강 소재 분야의 경쟁력 재고에 기여하고자 진행되었다.



Figure 2. 기존 신소재 개발 기간은 최소 수 년에서 수십 년까지 매우 길다.

프로젝트 대상 소재는 우리의 실생활에서 흔히 접할 수 있는 자동차, 항공기, 인공관절(또는 임플란트)에 적용되고 있는 소재들로 선정하였다. 각 어플리케이션(자동차, 항공기, 인공관절)에는 부품 별로 다양한 소재들이 사용되고 있는데 그 중 가장 대표적인 소재인 이상강(dual phase steel, DP steel), 탄소복합소재(carbon fiber reinforced plastic, CFRP), 티타늄합금(titanium alloy, Ti64)으로 특정하였다.

이하에서는 대상소재들을 순서대로 DP steel, CFRP, Ti64로 표기하였다. 선정한 소재들은 사용되는 환경에 따라 목표 특성치가 정해진다.




강화상

기지상

DP steel의 경우 자동차 하부 프레임에 적용되는 소재이기 때문에 엔진, 트랜스미션, 제동 장치 등과 같이 차량 내 중요 부품들이 충격 및 변형으로 인해 손상되는 것을 방지해 주어야 하며, 그에 따라 높은 강도와 경도, 인성이 요구된다. 추가적으로 원하는 형태로 쉽게 제조하기 위해서 우수한 가공성이 요구된다.

Figure 3. DP steel의 미세조직 관찰 결과(주사전자현미경), 강화상(밝은 색)과 기지상(어두운 색)을 확인할 수 있다.




강화상

기지상

CFRP의 경우 뛰어난 강도를 지니는 탄소 섬유와 가벼운 플라스틱의 복합소재로 가벼우면서도 높은 강도 및 피로 수명이 요구되는 항공기 소재로 각광받고 있다.

Figure 4. CFRP 미세조직 관찰 결과(주사전자현미경), 밝은 강화상(탄소섬유)과 어두운 기지상(현미경 관찰을 위해 금속코팅된 플라스틱)을 확인할 수 있다.



기공

기지상

Ti64 소재는 경금속에 속해 가볍고, 강도 조절이 용이한데다 잘 부식되지 않는 특성 때문에 부식이 잘 되는 환경인 인체 내부에 사용하는 의료용 소재로 많이 채택되고 있다.

Figure 5. Ti64 미세조직 관찰 결과(주사전자현미경), 기공과 기지상이 나타난다.

이처럼 어플리케이션에 적절한 소재를 채택하는 것도 중요하지만, 해당 소재의 꾸준한 개선 개발 연구를 통해 최적 특성을 끌어올리는 것이 원자재 절약을 통한 원가 절감, 최종 제품의 품질 향상 측면에서 가장 중요한 과제라고 할 수 있다.



Figure 6. 어플리케이션 별 적용 소재와 그 사용환경에 맞게 요구되는 특성들을 나타낸 이미지

자동차 소재로 사용되고 있는 DP steel 을 예로 들어 설명하겠다. DP steel 에서 중요한 경도 특성을 향상시키기 위해서는 제조 공정 중 열처리 조건을 제어해야 한다. 열처리 과정에서 생성되는 미세조직이 DP steel 의 특성을 결정하기 때문이다. 열처리를 포함한 여러 공정을 거쳐 제조된 DP steel 의 미세조직을 관찰하면 열처리가 제대로 수행된 경우 강화상(reinforcement)이 적절히 생성되어 나타난다. 하지만 열처리가 부적절하게 수행된 경우 현저히 낮은 분율의 강화상과 함께 예상치 못한 결함들이 생성될 수 있으며, 이로 인해 오히려 특성이 저하될 수 있다. 또한 경도 특성이 과도하게 높아진 경우, 갑작스런 파괴가 발생하는 특성이 생기기 때문에 오랜 시간에 걸쳐 미세조직 관찰, 특성 측정을 통해 최적 공정 조건을 도출하고 어플리케이션에 최적화된 소재를 개발해야 한다.

나머지 두 소재, 항공기와 생체재료에 적용되는 CFRP와 Ti64도 마찬가지로 요구 특성을 만족하기 위해 carbon fiber 상이 제대로 잘 분산되어 있는지, 인공관절에 적용하기 위해 실제 인체의 골밀도와 유사한 기공도를 가지고 있는지 미세조직 관찰에 기반한 특성치 분석, 그리고 공정 조건 개선이 반복적으로 긴 시간 동안 수행되어야 한다.

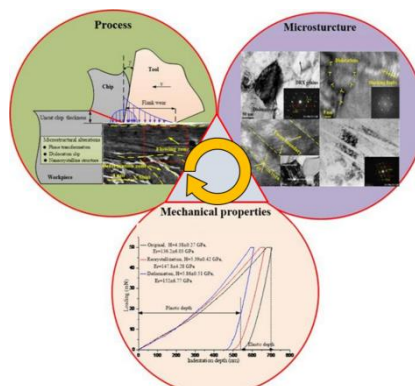


Figure 7. 공정-미세조직-특성의 상관관계. 소재 개발단계에서 이 3가지 조건들이 유기적으로 연결되어야함을 나타낸다.

1-3. 적용 기술

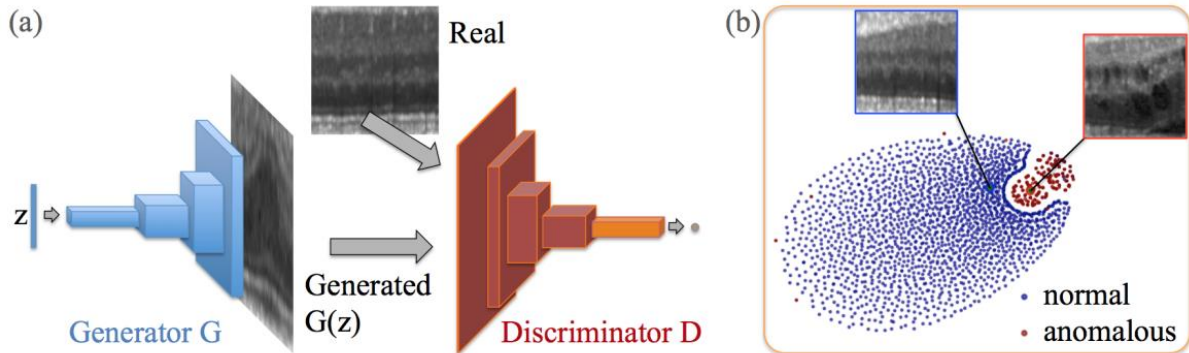


Figure 8. Anomaly-GAN 학습하는 과정(a)과 비정상 데이터를 분류(b).

본 프로젝트에 적용된 기술은 Anomaly-GAN 계열의 모델이다. Anomaly-GAN 은 정상 데이터만을 학습시킨 GAN을 활용하여 비정상 데이터를 분류하는 Unsupervised 모델이다. 주로 정상 데이터가 비정상 데이터보다 훨씬 많은 제조 분야나 의료 분야에서 많이 쓰이는 Anomaly-GAN은 정상 데이터만을 학습시켜 비정상적인 부분을 검출하면 되기 때문에 더 간편하고 특징 파악이 빠르고 쉽다는 장점이 있다.

특히 Anomaly-GAN은 기존의 신소재 연구 단계에 적용된 CNN과 같은 Supervised 모델과 달리 Unsupervised 모델이기 때문에 라벨링이 불필요하다는 점에서 데이터 수집과 정제 단계에서의 수고를 많이 덜 수 있다는 효율성도 있었다. 이러한 점들을 활용하여 신소재의 연구/개발 단계에서도 신소재의 미세조직을 정확하게 관찰하고 미세조직으로부터 소재의 특성을 빠르게 파악할 수 있다고 판단해, 본 프로젝트에 Anomaly-GAN 계열의 모델을 사용하게 되었다.

본 프로젝트에서의 Anomaly-GAN은 특징이 없는 소재 데이터만을 학습한 GAN 모델을 활용해 특징이 있는 미세조직 데이터에 대해서 특징만을 검출해 특징적인 부분의 분율(fraction)을 계산하는 것을 목표로 했다. 그리고 보통의 경우 Anomaly-GAN은 Anomaly Score를 제시해 비정상적인 부분의 정도를 표현하지만, 본 프로젝트에서는 Anomaly Score보다 미세조직의 분율에 집중했다.

특정 소재에 대한 미세조직의 분율을 구하는 것은 소재의 특성을 예측하는 것의 기반이 되기 때문에 매우 중요했다. 특징이 없는 소재 데이터를 활용해 Generator가 특징이 없는 데이터를 생산해내면, Discriminator는 그에 상응하는 피드백을 주어 Generator와 Discriminator를 동시에 훈련시켰다. 그 결과, 해당 프로젝트에서는 Anomaly-GAN 모델이 소재의 미세조직의 특징적인 부분을 잘 검출해 내 특징적인 부분의 분율을 구해 소재의 특성을 예측하는 방식으로 진행되었다.

2. 시스템 구현

2-1. 데이터 수집 및 생성

신소재와 관련된 데이터는 국가의 고유 자산인 경우가 많고 관련 연구소끼리 데이터가 공유되지 않는 경우가 많아 오픈 된 Dataset을 구하는 것이 매우 어려웠다. 그렇기 때문에 신소재 관련 논문 등에서 이미지를 직접 발췌해 Dataset을 구성하는 방법으로 데이터를 수집했다. 수집 결과, Dataset은 크게 소재의 특징적인 부분이 없는 Train Dataset과 본 프로젝트에서 시범적으로 선정한 3가지 소재의 특징이 잘 드러난 Test Dataset으로 구성되었다.

(1) Train Dataset




Figure 9. Test Data의 특징을 잘 검출하기 위해 보편적인 금속의 초기형태인 Ferrite만으로 구성된 Train Dataset. Train Dataset은 Test Data의 특징을 잘 분류하기 위해 특징적인 부분이 없는 소재인 Ferrite Steel로 구성되었다. Ferrite Steel은 보편적인 금속의 초기 형태로, Test Dataset의 특징을 잘 검출해낼 것이라고 판단했다. 그러나 초기에 모은 데이터의 수가 원활한 학습을 하기에는 부족했기 때문에, Data Augmentation을 진행해 데이터를 다양한 각도로 회전시키거나 반전시켜 Train Data의 수를 늘릴 수 있었다.

(2) Test Dataset

Test Dataset 은 특정 미세조직의 분율을 통해 소재의 특성을 알기 위한 Dataset으로, 본 프로젝트에서 시범적으로 선정한 3가지 소재인 DP Steel(이중상 강철), CFRP(탄소 섬유 강화 플라스틱), Ti64(티타늄 합금)의 특징적인 부분이 잘 드러난 데이터를 중심으로 구성되었다.

* DP Steel (이중상 강철)




Figure 10. DP steel(이중상 강철)에 대한 Test Dataset

DP Steel(Dual Phase Steel)은 자동차 프레임에 많이 쓰이는 소재이다. 자동차 프레임에 해당 소재를 사용하기 위해서는 경한 정도(hardness)가 중요하다. 따라서 DP Steel 에 대해서는 단단한 정도인 경도(hardness)를 측정하기 위해 해당 미세조직이 잘 드러난 데이터를 모았다.

* CFRP (탄소 섬유 강화 플라스틱)




Figure 11. CFRP(탄소 섬유 강화 플라스틱)에 대한 Test Dataset

CFRP(Carbon Fiber Reinforced Plastic)는 비행기 겉면에 많이 사용되는 소재이다. CFRP가 비행기 겉면에 적절하게 사용되기 위해서는 해당 소재의 원형 섬유조직이 고르게 분포되어있어야 한다. 따라서 CFRP 에 대해서는 원형 섬유조직이 고르게 분산되어있는지를 알기 위해 분산도(dispersion)를 측정하기 위한 데이터를 수집했다.

* Ti64 (티타늄 합금)




Figure 12. Ti64(티타늄 합금)에 대한 Test Dataset

Ti64는 인공관절과 같은 생체재료에 많이 쓰이는 소재이다. 해당 소재가 원래 뼈와 잘 어우러지기 위해서는 해당 소재가 골밀도와 비슷한 기공도를 가지고 있는 것이 중요하다. 따라서 Ti64에 대해서는 전체에서 구멍이 차지하는 비율인 기공도(porosity)를 측정하기 위한 데이터를 수집했다.

2-2. 시스템 구조

다양한 소재의 개발 단계에서 인공지능을 활용하여 미세조직 관찰 결과를 분석하고 소재 특성 예측 기능을 구현하는 시스템인 GANgineer 프로그램 개발을 진행하였다. 이는 신소재 연구 단계에서 겪는 복잡한 미세조직의 정량적 분석의 어려움 해결 및 예측 정확도 향상을 통하여 신소재 연구에 기여할 것으로 예상된다. GANgineer 시스템의 구조 및 동작 원리는 아래의 이미지와 같으며 자세한 설명은 다음과 같다.

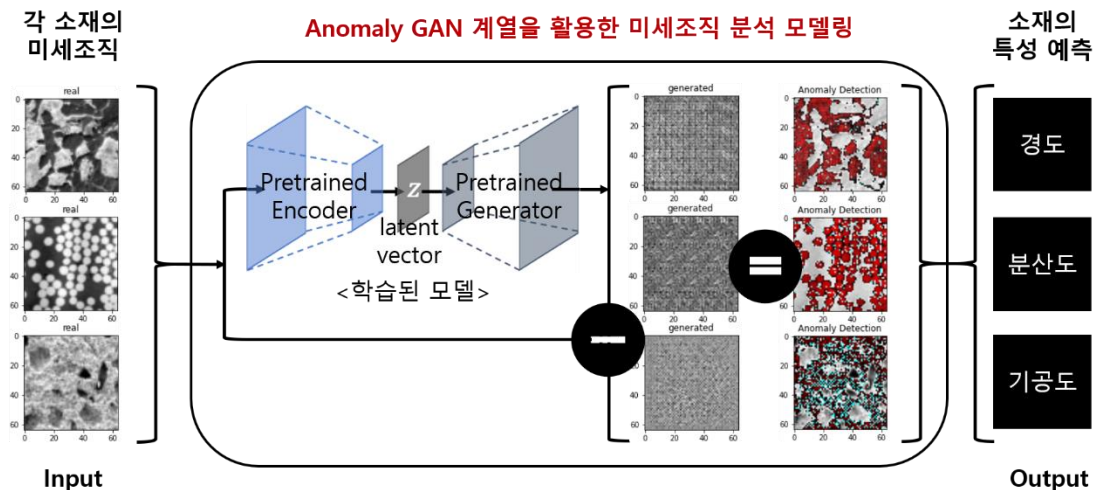


Figure 13. GANgineer 시스템 구조

(1) Input: 각 소재의 미세조직

분석을 통하여 특성을 알고자 하는 소재의 미세조직을 Input으로 한다. 이 프로젝트에서는 신소재 관련 논문에서 수집한 3가지 소재인 DP steel(이중상 강철), CFRP(탄소 섬유 강화 플라스틱), Ti64(티타늄 합금)의 SEM(주사 전자 현미경)으로 촬영한 미세조직 사진, 즉 Test Dataset을 Input값으로 하였다.

(2) 학습된 Anomaly GAN 모델을 통한 미세조직 분석

Anomaly Detection을 위하여 만들어진 GAN 계열 모델인 AnoGAN, Fast-AnoGAN, GANomaly 3가지 모델에 대한 비교 분석을 통하여 미세조직 분석 모델링을 진행하였다. 각 모델에 대한 자세한 설명은 아래의 2-3. 모델 소개를 참고하길 바란다.

Anomaly GAN 계열 모델 학습 시, Train Data로는 보편적인 금속의 초기 형태인 Ferrite 미세조직 사진을 활용하였다. 이를 통하여 학습된 모델이 미세조직의 특징 존재하지 않는 사진(generated)을 생성하도록 하였다.

Input으로 들어온 각 소재의 미세조직 사진과 학습된 모델을 바탕으로 generated 된 사진의 차이를 통하여 Anomaly Detection 부분을 추출한다. Anomaly Detection된 부분은 빨간색과 파란색으로 표시함으로써 각 소재의 미세조직 특징을 시각적으로 확인할 수 있으며, 특징적 부분의 분율 측정을 통하여 정량적 분석이 가능하다.

(3) Output: 소재의 특성 예측

GANgineer 시스템을 통한 최종적인 Output은 각 소재의 특성 예측 값이다. 각 소재의 특성 예측 값은 미세 조직 분석 모델링을 바탕으로 구한 분율 값을 바탕으로 예측하였다.

Application 별 사용 소재와 사용 환경에 따라 요구되는 소재의 특성이 다르기 때문에, 소재에 따라 예측하고자 하는 특성치 Output은 다르게 나타난다. 이 프로젝트에서 활용된 Test Dataset(Test Input)의 경우 각 소재에 따른 최종 Output은 다음과 같다.

* DP steel(이중상 강철)

자동차에 많이 활용되는 소재로 단단한 정도가 중요하기 때문에 *경도(Hardness)* 값을 Output으로 한다.

* CFRP(탄소 섬유 강화 플라스틱)

비행기 외곽에 활용되는 재료로 탄소 섬유의 고른 분산이 중요하기 때문에, *분산도(dispersion)*을 Output으로 한다. 이 때, 분산도는 모델링을 통해 계산한 분율로 측정하기 어렵기 때문에 상관계수 값을 계산하여 측정하였다.

* Ti64(티타늄 합금)

인공 관절 등 생체 재료에 많이 활용되는 재료로 골밀도와 유사한 기공율을 가져야 하므로, *기공도(porosity)*를 Output으로 한다.

2-3. 모델 소개

(1) 이상 탐지(Anomaly Detection) 기술 소개

* 이상 데이터(Anomalous Data)의 정의

이 내용은 [DEEP LEARNING FOR ANOMALY DETECTION: A SURVEY](#)을 참고함을 먼저 밝힌다.

이상 탐지(Anomaly Detection)는 이름에서부터 알 수 있듯이 abnormal 데이터를 normal 데이터로부터 구분하는 것이다. 우선 abnormal 데이터란, 직관적으로 생각 할 때, 아래의 그림과 같이 데이터 샘플이 모인 구간에서 멀리 떨어진 샘플들을 뜻한다.




Figure 14. normal 데이터와 abnormal 데이터의 정의

위 그래프의 N1과 N2 영역에 거의 모든 관측치들이 몰려 있기에 이들은 normal 데이터로 분류할 수 있다. 하지만 나머지 O 관측치들은 normal 관측치 영역과 멀리 떨어져 abnormal 데이터로 분류할 수 있다. 정리하자면 normal 데이터의 분포에 속하지 않는 이상치(outlier)를 abnormal 데이터라고 할 수 있는 것이다.

* 기존의 딥러닝 기반 이상 탐지(Anomaly Detection) 기술

이상 탐지(Anomaly Detection)를 수행하는 방법에는 여러 가지가 있다. 정상 데이터의 분포를 정의하는 통계적인 방법도 있고, KNN과 같은 정통적인 머신러닝 알고리즘 방법 또한 있다. 하지만 최근에는 딥러닝을 이용한 이상탐지가 좋은 성능을 보이고 있다. 아래는 딥러닝 기반의 이상탐지 기술들에 대한 분류다.

Nature of Input Data

- Sequential (eg. voice, text, music, time series, protein sequences)
 - Non-sequential data (eg. images, other data)
-

Availability of labels

1) Supervised

- Training a deep supervised binary or multi-class classifier, using labels of both normal and anomalous data instances
- lack of availability of labeled training samples

2) Semi-supervised

- Leverage existing labels of single (normally positive class) to separate outliers
- ex) deep auto encoders - train them on data samples with no anomalies. normal class samples would produce low reconstruction errors, abnormal class would produce high reconstruction error

3) Unsupervised

- Solely based on intrinsic properties of the data instances
 - PCA, SVM, Isolation Forest
 - Auto encoder, RBM, DBN, RNN, LSTM
-

Training Objective

1) Deep Hybrid Models (DHM)

- Use deep neural networks mainly auto encoders as feature extractors
- Features are input to traditional anomaly detection algorithms (ex, such as one-class SVM)
- Lack of trainable objective customized for anomaly detection

2) One-Class Neural Networks (OC-NN)

- data representation in the hidden layer is driven by the OC-NN objective
- customized for anomaly detection

(2) 사용 모델 소개

* AnoGAN

AnoGAN은 Anomaly Detection with GAN의 준말로 Anomaly Detection에 처음으로 GAN을 적용한 논문, [Unsupervised Anomaly Detection with Generative Adversarial Networks to Guide Marker Discovery](#)을 구현한 모델이다.

위 논문이 수행하고자 한 task는 망막의 이미지 샘플을 보고 샘플 이미지가 질병을 가지는지, 질병을 가진다면 어느 부분이 abnormal한지 찾아내는 것이다. 이를 위해 GAN을 이용한 비지도 학습을 수행한다. 아래 그림은 논문의 전체적인 아이디어를 잘 보여준다. 모델의 학습부에선 normal 데이터로만 GAN을 학습하여 normal 데이터를 잘 생성할 수 있는 모델을 만든 다음, 모델의 평가부에서 abnormal 데이터를 이 모델의 입력으로 넣어 정상 이미지로 얼마나 비슷하게 복원할 수 있는지를 확인한다. 이때 특정 수치(Threshold)를 넘는 픽셀은 abnormal 픽셀로 추출되게 된다.




Figure 15. AnoGAN 모델의 동작 형태

AnoGAN의 경우, DCGAN을 차용했고, normal 데이터만 사용하여 label이 주어지지 않았기에 논문에서는 이를 unsupervised learning이라고 정의한다. normal 데이터만으로 Generator를 학습시킨다는 것은 $x=G(z)$ 의 매핑을 학습시키는 것이다. z 는 잠재 공간 Z 로부터 샘플링 된 input noise의 1차원 벡터이고, x 는 manifold \mathcal{X} 를 따라 분포하는 2차원 이미지다.

- manifold \mathcal{X} ($x = x_{k,m} \in \mathcal{X}$)




Figure 16. Generator 학습, $x=G(z)$ 모형

정상 이미지들이 위와 같은 manifold를 이루고 있다면 manifold 바깥에 위치한 이미지는 비정상 이미지를 나타낸다. 여기서 제일 중요한 점은 normal 데이터로 학습시킨 GAN의 Generator가 z 에서 x 로의 매핑을 나타낸다는 것이다.

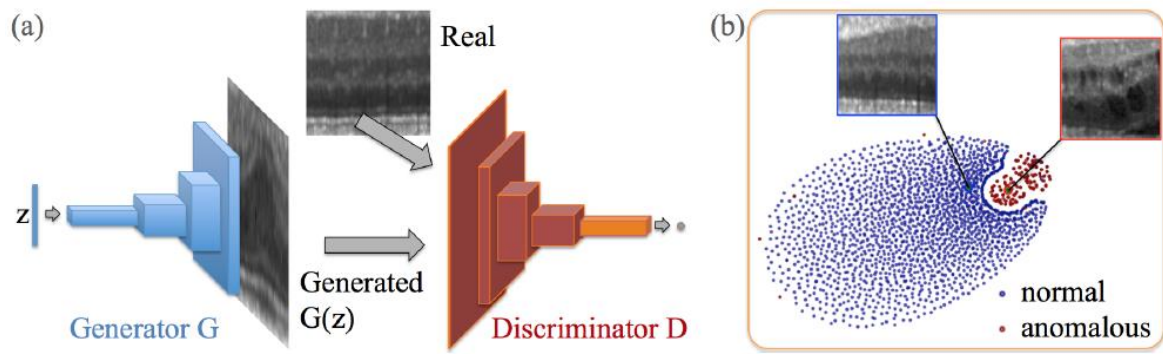


Figure 17. AnoGAN 전체 모델 구조

위 fig는 AnoGAN 전체 모델 구조를 나타낸다. 학습과정 (a)는 GAN과 동일하다. random noise z 를 샘플링하여 Generator의 입력으로 주어서 가짜 이미지 $G(z)$ 를 만들어 낸다. 그리고 이를 실제 이미지와 구분할 수 있는 Discriminator의 인풋으로 넣어서 이로부터 나오는 loss를 역전파 하여 Generator와 Discriminator를 업데이트한다. 이후 평가과정 (b)에서 abnormal 입력을 분류한다.

GAN 모델의 단점이자 AnoGAN의 단점은 바로 이 구조에 있다. 미리 학습한 Generator와 Discriminator를 사용하더라도 매번 최적의 z 를 학습해야만 한다. 이런 구조로 인한 느린 실행 속도는 AnoGAN을 프로그램에 임포트 할 수 없는 이유가 된다.

최적의 z 를 얻기 위한 과정을 DCGAN 논문, [Unsupervised Representation Learning with Deep Convolutional Generative Adversarial Networks](#)에서는 “Waling in the latent space”라는 말로 표현한다.




Figure 18. Waling in the latent space

위 이미지는 DCGAN에서 noise z 의 값을 조금씩 조정해 가면서 이미지를 생성했을 때, 이미지가 서서히 바뀌는 것을 나타내는 사진이다. 즉, 잠재공간 Z 상에서 가까이 있는 두 z 를 샘플링 하면 비슷한 두 이미지가 생성된다. 다른 말로 Generator에게 쿼리 이미지 z 가 주어졌을 때, 매핑 되는 z 를 얻기 위해서는 Generator가 최대한 x 와 비슷한 이미지를 만들도록 z 를 움직여야 한다는 것이다. 이런 최적의 z 를 찾기 위한 과정은 다음과 같다.

1. z_1 를 랜덤하게 샘플링 한다.
2. 이를 학습된 Generator에 인풋으로 넣는다.
3. 생성된 이미지 $G(z_1)$ 을 보고 z_1 의 coefficient를 업데이트 한다.
4. 1~3을 반복하여 x 와 가장 비슷한 이미지 $G(z^*)$ 를 찾는다. 그러면 잠재공간 Z 상에서 z 의 최적의 위치를 찾은 것이다.

단, 노이즈 자체를 업데이트 하는 것이 아니라 z 의 coefficient를 업데이트하는 것임을 주의해야한다.

z 의 coefficient를 업데이트하기 위한 loss function은 residual loss와 discrimination loss 두 부분으로 나뉜다.

$$LR(z\gamma)=\sum ||x-G(z\gamma)||$$

Figure 19. z의 loss func. Residual loss

Residual loss는 생성된 이미지 $G(z)$ 와 쿼리 이미지 x 가 얼마나 일치하는지를 나타낸다. 만약 완벽한 Generator를 학습하여 완벽한 매핑 $x = G(z)$ 를 얻었다면 x 와 $G(z)$ 는 완벽히 일치할 것이고, residual loss의 크기는 0이 될 것이다.

$$LD(z\gamma)=\sum ||f(x)-f(G(z\gamma))||$$

Figure 20. z의 loss func. Discrimination loss

Discriminator loss는 생성된 이미지가 학습된 manifold x 위에 있도록 강제한다. GAN의 Adversarial Training에서 실제 이미지의 discriminator loss와 같은 역할을 수행한다. 하지만 DCGAN의 논문에서는 Discriminator의 출력 스칼라 값을 사용하는 대신 중간 layer $f(\cdot)$ 의 출력으로 나오는 intermediate feature representation을 사용하여 더 풍부한 표현을 얻을 수 있다.

위 두 loss를 합친 z의 최종 loss는 다음과 같다.

$$L(z\gamma)=(1-\lambda) \cdot LR(z\gamma)+\lambda \cdot LD(z\gamma)$$

Figure 21. AnoGAN(DCGAN)의 z 학습을 위한 최종 loss fuc.

새로운 샘플 x 의 anomaly 여부를 판별하기 위해서는 이 loss값을 그대로 anomaly score로 사용하면 된다. 또 이미지의 특정 픽셀의 abnormal 여부를 판별하기 위해서는 Residual score $xR=|x-G(z\gamma)|$ 를 사용한다. 이를 통해 원래 이미지 x 와 생성된 이미지 $G(z\gamma)$ 간 다른 부분을 감지할 수 있다.

* f-AnoGAN

f-AnoGAN은 Fast Unsupervised Anomaly Detection with GAN의 준말로, 매번 최적의 z 를 학습해야만 하는 AnoGAN의 단점을 Encoder E로 해결한 논문, [f-AnoGAN: Fast unsupervised anomaly detection with generative adversarial networks](#)을 구현한 모델이다.

논문에서는 E를 활용한 빠른 z 의 생성을 "fast mapping technique of new data"라고 표현하고 있다. 이때 매핑 방법은 Encoder를 기반으로 하고, Discriminator feature residual error 및 image reconstruction error $G(z)$ 를 포함하는 훈련된 모델을 기반으로 anomaly score를 통해 anomaly detection을 수행하게 된다.

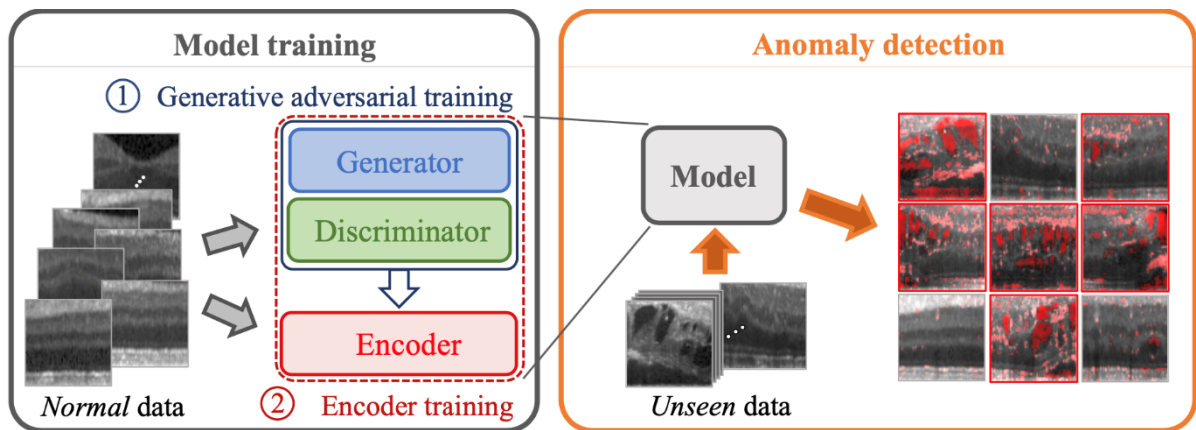


Figure 1: Anomaly detection framework. Both steps of model training, generative adversarial training (yields a trained generator and discriminator) and encoder training (yields a trained encoder), are performed on *normal* (“healthy”) data and anomaly detection is performed on both, unseen healthy cases and anomalous data. (Best viewed in color)

Figure 22. fast mapping technique of new data

위와 같이 Encoder 모델을 활용한 입력 이미지의 latent space로의 매핑이 f-AnoGAN의 핵심이다. 비슷한 방법인 AnoGAN과 비교를 해보면 그 차이점을 확실히 확인할 수 있다.

AnoGAN은 최적의 z 를 학습하기 위해 residual loss + discrimination loss를 loss function으로 두고서 역전파를 수행한다. 이때의 residual loss 수식을 그대로 anomaly score를 계산하게 된다. 해당 방법은 학습 이미지의 크기가 작으면 효율적이고 나름 빠르게 진행되겠지만, 이미지 사이즈가 크면 클수록 많은 정보를 고려해야하기에 매번 z 를 random하게 초기화하는 AnoGAN의 방법으로는 제대로 매핑을 수행하지 못하는 경우가 발생할 수 있다.

f-AnoGAN은 이런 문제를 해결하고자 AutoEncoder를 착안했다. AutoEncoder는 입력 정보들을 잘 설명할 수 있는 latent vector로 차원 압축을 수행하고, 이후 Decoder를 통해서 복원하는 모델이다. 이 과정에서 사용된 Encoder 모델만 가져와 입력 이미지를 latent space에 매핑하는 모델을 AnoGAN에 추가한 것이 f-AnoGAN의 전부다. 이렇게 Encoder를 활용한 normal 데이터 입력을 latent space에 매핑하는 과정을 항등 변환(identity transformation)이라고 볼 수 있다.

다시 말해 f-AnoGAN은 Deep Encoder Network으로 AnoGAN에서는 불가능했던 inverse mapping을 실현하여 $E(x) = z$ 를 가능하게 한다. 해당 논문에서는 Encoder 학습을 위해 2가지 방법을 제시하고 있다.

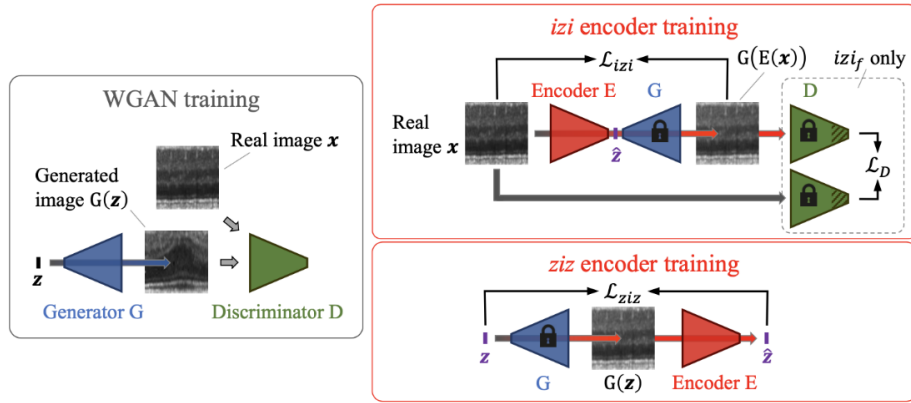


Figure 2: Components of the proposed anomaly detection framework training. *Wasserstein GAN (WGAN)* training yielding learned parameters for the generator (G) and discriminator (D). Three possible variants of *encoder training* with fixed parameters of G (and D) where only the encoder parameters are adapted. 1) *izi encoder training*: minimizing the loss \mathcal{L}_{izi} based on the residual of real input images and “reconstructed” images, 2) *izi_f encoder training*: jointly minimizing the loss \mathcal{L}_{izi} based on the residual of real input images and “reconstructed” images and the loss \mathcal{L}_D based on the residual on discriminator’s features, and 3) *ziz encoder training*: minimizing the loss \mathcal{L}_{ziz} based on the residual of randomly sampled and reconstructed locations in *z*-space (latent space).

Figure 23. f-AnoGAN의 Encoder 학습 방법

1. ziz architecture: 생성된 이미지로 Encoder 학습

훈련 중 latent space Z 로부터 random하게 샘플링 된 샘플 z 는 학습된 Generator를 통해 image space 에 매핑 되고 Encoder는 이를 다시 latent space에 매핑하도록 훈련된다. 따라서 ziz architecture의 경우 GAN 학습 시 사용한 normal 데이터가 필요없다.

$$\mathcal{L}_{ziz}(\mathbf{z}) = \frac{1}{d} \|\mathbf{z} - E(G(\mathbf{z}))\|^2,$$

Figure 24. ziz architecture의 loss func.

ziz 구조의 loss function은 z 와 $E(G(z))$ 의 MSE를 최소화하는 방향으로 학습이 진행된다. 이 방식은 학습할 때 생성된 이미지만 잘 매핑 될 뿐 쿼리 이미지가 들어오면 제대로 매핑하지 못하게 되는 단점이 있어 f-AnoGAN 논문에서는 사용하지 않는다.

2. izi architecture: 실제 이미지로 Encoder 학습

훈련동안 실제 이미지에서 latent space Z 로 encoding되어 매핑하는 과정은 Encoder로 수행되고, encoding된 z 를 다시 image space로 매핑하는 것은 학습된 Generator가 수행한다. 따라서 izi architecture의 경우 GAN 학습 시 사용한 normal 데이터를 다시금 사용하게 된다.

$$\mathcal{L}_{izi}(\mathbf{x}) = \frac{1}{n} \|\mathbf{x} - G(E(\mathbf{x}))\|^2,$$

Figure 25. izi architecture의 loss func.

izi 구조의 loss function은 입력 이미지 x 와 생성된 이미지 $G(E(x))$ 의 MSE residual loss를 최소화하는 방향으로 학습이 진행된다. ziz 구조와 다르게 실제 쿼리 이미지에 대해 제대로 매핑을 수행하지만, $G(z)$ 를 바로 구하지 못하고 $G(E(x))$ 를 구하기에 image space로 다시 매핑하고 image-to-image residual loss를 계산하여 image-to-z 매핑의 정확도를 간접적으로 구해야 한다는 단점이 존재한다.

다르게 표현하자면 입력 x 가 normal 데이터라면 문제가 없지만 abnormal 데이터라면 residual이 적은 이미지가 생성될 수 있다. 이러한 문제점에서 논문에서는 feature space를 loss로 사용하여 매핑 과정을 수행하는 izif architecture를 고안하고 있다.

3. izif architecture: Discriminator의 feature space가 가지는 residual loss도 추가적으로 학습

$$\mathcal{L}_{izif}(\mathbf{x}) = \frac{1}{n} \cdot \|\mathbf{x} - G(E(\mathbf{x}))\|^2 + \frac{\kappa}{n_d} \cdot \|f(\mathbf{x}) - f(G(E(\mathbf{x})))\|^2,$$

- n_d : Discriminator 중간 계층 feature space의 dimension

- κ : weight factor

Figure 26. izif architecture의 loss func.

수식 속 Discriminator features는 AnoGAN에 사용된 loss와 관련이 있음을 확인할 수 있다.

Discriminator feature는 GAN을 학습할 때 얻은 parameter들을 사용한 것이다. feature space loss는 image-to-z 매핑의 가이드를 제공하는 역할을 수행하게 된다.

위의 수식들로 f-AnoGAN의 GAN 모델과 Encoder가 학습이 잘 됐다면, 이제는 쿼리 이미지를 입력으로 넣어 anomaly score를 계산하게 된다. 그 과정은 image-level과 feature-level로 나뉘어 image-level 단의 anomaly detection중에 쿼리 이미지와 생성된 이미지의 deviation을 score로 나타내게 된다. 이 스코어를 anomaly score라고하고 아래의 수식으로 그 값을 계산한다.

Image-level와 feature-level에서 계산 된 loss를 total loss로 사용

Anomaly Score

$$\mathcal{A}(\mathbf{x}) = \mathcal{A}_R(\mathbf{x}) + \kappa \cdot \mathcal{A}_D(\mathbf{x}),$$

Input image \mathbf{x} 와 reconstructed image $G(E(\mathbf{x}))$ 의 MSE residual loss

Image-level

$$\mathcal{A}_R(\mathbf{x}) = \frac{1}{n} \cdot \|\mathbf{x} - G(E(\mathbf{x}))\|^2,$$

Input image \mathbf{x} 와 reconstructed image $G(E(\mathbf{x}))$ 의 MSE residual loss

Feature-level

$$\mathcal{A}_D(\mathbf{x}) = \frac{1}{n_d} \cdot \|f(\mathbf{x}) - f(G(E(\mathbf{x})))\|^2$$

Figure 27. f-AnoGAN의 anomaly score

위 수식을 살펴보면 Loss-izif 수식과 동일함을 확인할 수 있다. 이는 f-AnoGAN의 anomaly score 계산에 학습 시 사용한 residual loss 수식을 그대로 사용한 것이라고 해석할 수 있다. 또, 주어진 모든 수식이 abnormal 이미지에서 높은 anomaly score를, normal 이미지에서 낮은 anomaly score를 계산한다. 이는 모델이 normal 이미지로만 학습하기에 normal 이미지와 유사한 입력 이미지가 낮은 anomaly score를 가진다는 맥락으로 이해할 수 있다.

* GANomaly

GANomaly는 AnoGAN과 BiGAN, 두 선행 연구를 종합한 연구 [GANomaly: Semi-Supervised Anomaly Detection via Adversarial Training](#)를 구현한 모델이다. GANomaly 모델은 normal 이미지만으로 구성된 학습 데이터셋을 학습하며 normal 이미지의 manifold X 를 학습하는 동시에, AutoEncoder는 효율적으로 이미지를 z 로 encoding하는 방법을 학습한다.

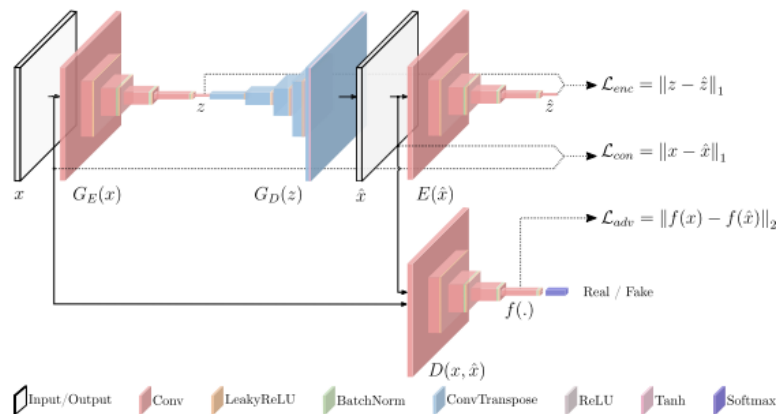


Figure 3. GANomaly architecture and loss functions from (Akçay et al., 2018).

Figure 28. GANomaly Network Architecture

위의 GANomaly network 구조에서 확인할 수 있듯이, 모델은 크게 Generator와 Discriminator로 나뉘게 된다. Generator는 다시 Generator_Encoder, Generator_Decoder 그리고 Encoder로 구성된다. 실제 입력 이미지 x 는 AutoEncoder(= Generator_Encoder + Generator_Decoder)를 거쳐 \hat{x} 이 되고, 다시 Encoder를 거쳐 \hat{z} 이 된다. 이렇게 생성된 z 와 \hat{z} 의 mae loss를 계산한 값이 Loss_encoder가 된다.

GANomaly는 크게 다섯가지 측면에서 기여했다.

1. AutoEncoder 구조 활용

2. AutoEncoder 구조의 Generator와 Encoder의 활용으로 만들어진 Loss_encoder는 latent vector z 의 최적화를 도와 표현력을 높임

3. 세가지 Loss를 이용한 Generator Loss 정의

$$\mathcal{L} = w_{adv}\mathcal{L}_{adv} + w_{con}\mathcal{L}_{con} + w_{enc}\mathcal{L}_{enc} ,$$

Figure 29. GANomaly Generator Loss equation

$$\mathcal{L}_{adv} = \mathbb{E}_{\mathbf{x} \sim p_X} \|f(\mathbf{x}) - \mathbb{E}_{\mathbf{x} \sim p_X} f(G(\mathbf{x}))\|_2 ,$$

Figure 30. GANomaly Adversarial Loss equation

$$\mathcal{L}_{con} = \mathbb{E}_{\mathbf{x} \sim p_X} \|x - G(\mathbf{x})\|_1 .$$

Figure 31. GANomaly Contextual Loss equation

$$\mathcal{L}_{enc} = \mathbb{E}_{\mathbf{x} \sim p_X} \|G_E(\mathbf{x}) - E(G(\mathbf{x}))\|_2 .$$

Figure 32. GANomaly Encoder Loss equation

4. 간단한 계산의 anomaly score의 정의

저자는 \mathcal{L}_{enc} 를 사용하여 anomaly score의 계산을 간단히 했다.

$$\mathcal{A}(\mathbf{x}) = \|G_E(\mathbf{x}) - E(G(\mathbf{x}))\|_2 . \quad (12)$$

Figure 33. GANomaly의 평가 단계 anomaly score

5. 해석이 용이한 새로운 anomaly score의 정의

anomaly score의 간단한 해석을 위해 각 샘플 \hat{x} 에 대한 anomaly score를 계산하는 것을 제안했다. 개별적인 anomaly score 셋을 모으고 feature scaling을 적용해 확률적인 범위 $[0, 1]$ 에 모아서 평가하게 된

다.

$$s'_i = \frac{s_i + \min(S)}{\max(S) - \min(S)} . \quad (13)$$

Figure 34. GANomaly의 anomaly score 평가

2-4. 모델 비교 선정

(1) 모델 비교 기준

전체 이미지의 크기 대비 모델이 Anomaly로 탐지하는 부분의 비율을 분율로 정의한다. 논문에서 발췌한 Test 데이터의 실제 분율을 기준으로 모델이 예측하는 분율의 오차를 모델의 정확도 지표로 삼아, 우리는 각 소재에 대한 Test 데이터셋 40 여장을 확보하여 Ano-GAN, Fast Ano-GAN, GANomaly 모델의 전체 예측 분율 오차 평균을 계산할 수 있었다. 이때 가장 낮은 예측 분율 오차 평균을 기록하는 모델을 가장 높은 정확도를 기록하는 모델로 판단하고 해당 소재의 최적 모델로 선정할 수 있었다.

(2) DP Steel 최적 모델 선정

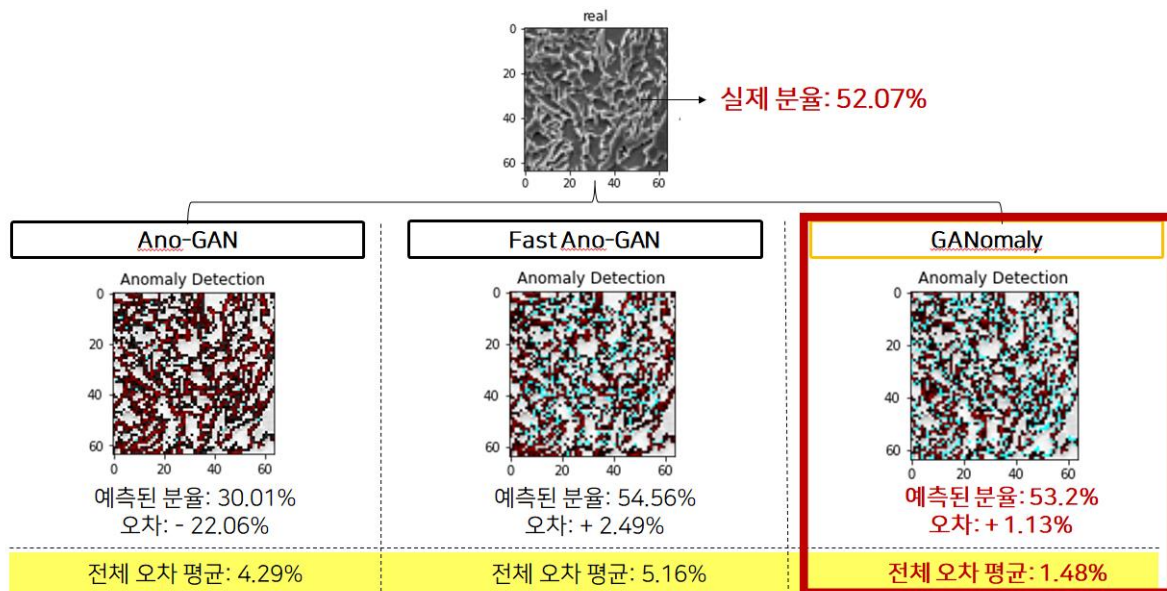


Figure 35. DP Steel 최적모델 비교 선정

전체 예측 분율 오차 평균이 1.48%로 가장 적은 GANomaly를 DP Steel에 가장 효과적인 모델로 선정했다.

(3) CFRP 최적 모델 선정

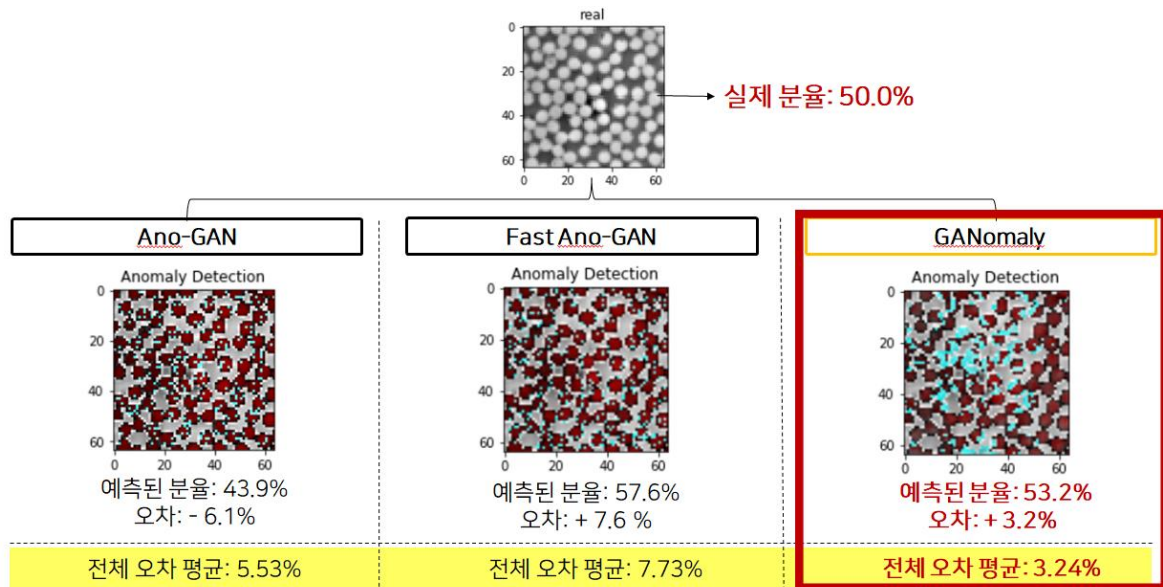


Figure 36. CFRP 최적모델 비교 선정

전체 예측 분율 오차 평균이 3.24%로 가장 적은 GANomaly를 CFRP에 가장 효과적인 모델로 선정했다.

(4) Ti64 최적 모델 선정

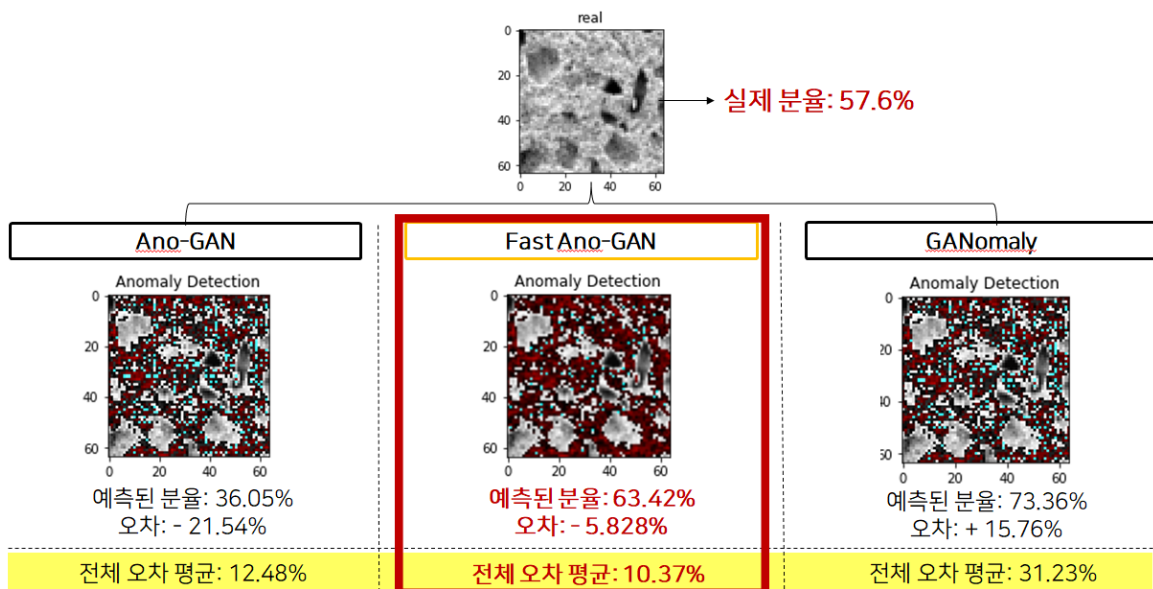


Figure 37. Ti64 최적모델 비교 선정

전체 예측 분율 오차 평균이 10.37%로 가장 적은 Fast Ano-GAN을 Ti64에 가장 효과적인 모델로 선정했다. 해당 미세조직에 대해 위에서 좋은 성적을 기록한 GANomaly가 적합하지 않은 이유는 GANomaly의 Semi-Supervised 학습 형태에 있다. Ti64의 3D 이미지를 같이 학습한 GANomaly 모델은 입력 이미지에 대해 3D

이미지의 분율을 추출하게 된다. 단면의 분율에서 소재 전체 분율을 예측하려는 우리의 목표와 측정 방식에 부합하지 않았기에 큰 예측 분율 오차 평균을 기록하게 됐다.

2-5. 프로젝트 산출물

(1) 기술 스택

Python, Pytorch, PyQt5, Qt Designer

(2) 프로그램 구조 및 설명



Figure 38. GANgineer 프로그램 실행 화면: DP Steel

- ① 프로그램의 메뉴탭으로 파일 저장, 편집, 설정, 도움말 기능들이 제공된다.
- ② 이중상 강철, 탄소 섬유 강화 플라스틱, 티타늄 합금으로 구성되어있으며, 선택시 해당 소재에 대한 미세조직 검출을 수행할 수 있다.
- ③ 미세조직 검출을 위한 이미지 파일들이 표시되는 곳으로 이미지 파일을 선택하면 7번 자리에 해당 사진이

표시된다.

④ 검출이 완료된 미세조직 파일들이 표시되는 곳으로 이미지 파일을 선택하면 8번 자리에 해당 사진이 표시되고 7번 자리의 입력 사진도 검출 전 사진이 표시된다.

⑤ '열기' 버튼을 클릭하면 윈도우 파일 다이얼로그가 나타나게 되며 이미지 파일을 선택할 수 있게 된다. '삭제' 버튼을 클릭하면 선택되어 있는 이미지 파일이 삭제된다.

⑥ '저장' 버튼을 클릭하면 출력된 결과물 윈도우 파일 다이얼로그가 나타나게 되며 저장 경로를 입력하게 되면 출력된 이미지들을 저장할 수 있다. '삭제' 버튼을 클릭하면 출력된 결과물 중 선택된 사진을 삭제할 수 있다.

⑦ 특성을 검출하고자 하는 미세조직의 이미지가 해당 영역에 표시된다.

⑧ 미세조직의 특성이 검출된 이미지가 해당 영역에 표시된다.

⑨ 미세조직을 검출하기 위한 버튼으로 해당 버튼을 누르고 검출이 완료되면 4번 영역에 검출이 완료된 이미지들이 나타난다.

⑩ Dual Phase Steel의 분율을 측정 결과와 해당 분율에 따른 경도를 측정하고 표시하게 되며 해당 분율과 경도를 통해서 신소재 개발에 있어 필요한 미세조직을 구해낼 수 있다.

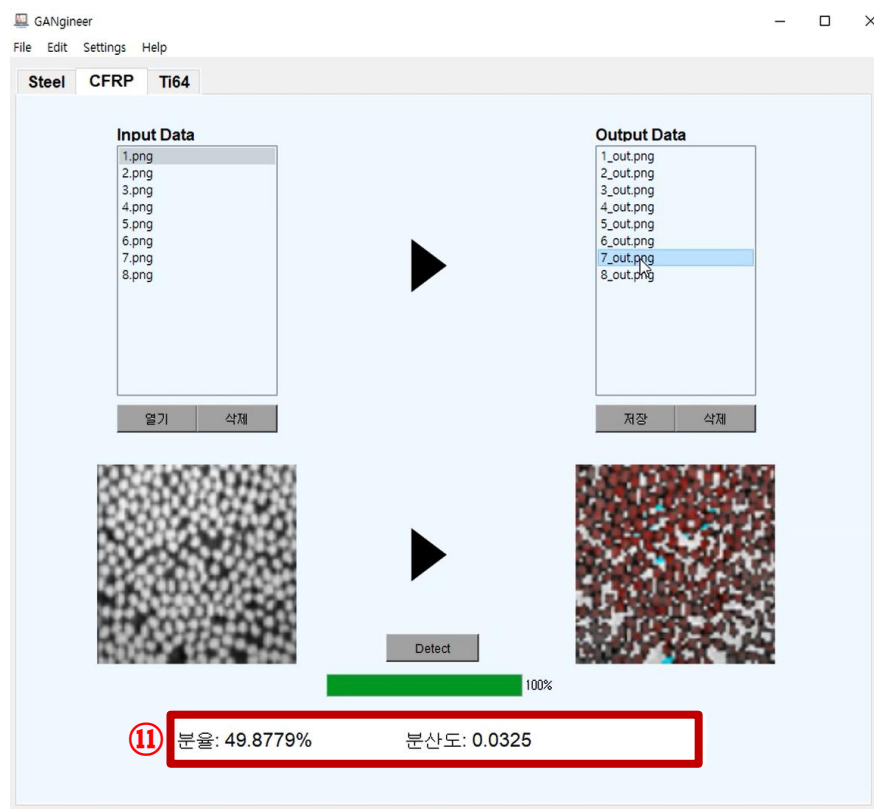


Figure 39. GANgineer 프로그램 실행 화면: CFPR

⑪ CFRP의 분율 측정 결과와 미세조직들의 분산도가 해당 영역에 표시되며 경량화되고 높은 강도의 플라스틱을 개발하는 단계를 수행할 수 있다.

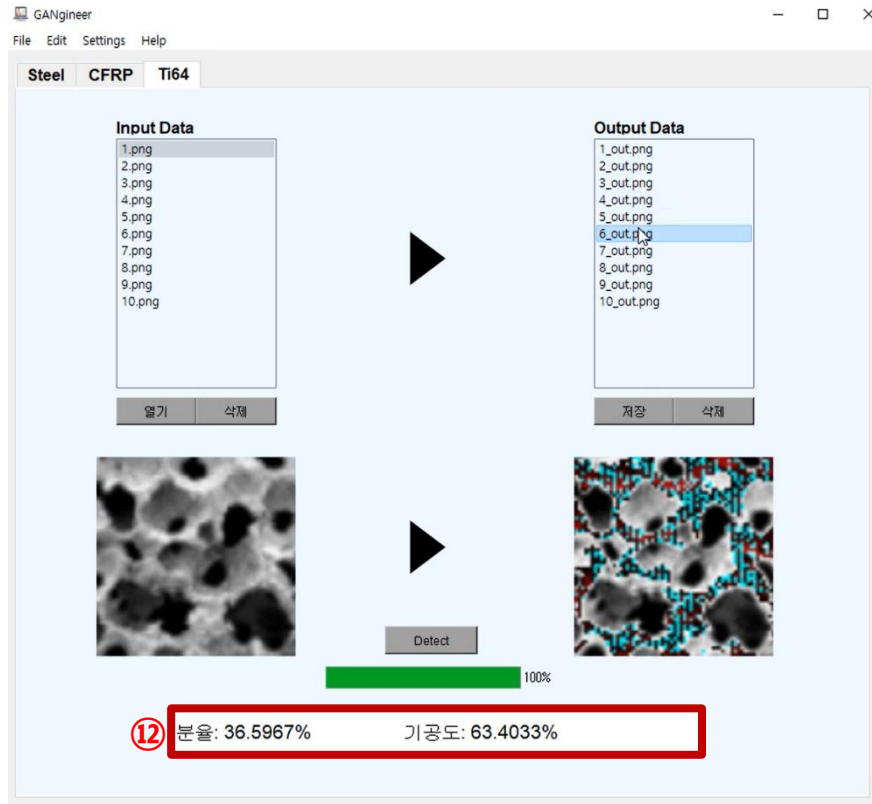


Figure 40. GANgineer 프로그램 실행 화면: Ti64

⑫ Ti64의 분율을 추출하고 조직들의 기공도를 측정한 값이 해당 영역에 표시되며, 생체 재료에 필요한 낮은 강도와 골밀도와 유사한 기공도를 구해낼 수 있다.

3. 기대 효과 및 향후 개선 사항

3-1. 기대효과: 신소재 개발 단계의 시간/비용 감축 및 정량적 분석 한계 극복



Figure 41. 프로젝트 기대효과 Before/After

현재 신소재 개발 단계에서 소재의 미세조직 분석 및 특성 측정 시, 사람이 직접 수행하는 구조로 인하여 상당한 시간과 비용이 소요된다. 이미지 분석 프로그램을 통하여 사람이 직접 미세조직 경계를 1장씩 추출하며, 하나의 소재당 최소 50장의 분석이 필요하기 때문이다. 또한, 복잡한 미세조직의 경우 정성적 분석은 가능하지만 정량적 분석이 어려운 한계점이 존재한다.

하지만, Anomaly GAN 계열의 모델을 바탕으로 한 인공지능을 활용하면, 대량의 미세조직 분석을 한 번에 가능하게 함으로써 이전보다 빠른 속도로 소재의 특성 예측 결과 도출이 가능하다. 또한, Anomaly Detection 된 부분을 바탕으로 분율 예측이 가능함에 따라, 정량적 분석이 가능하게 되어 현재 신소재 개발 단계 한계를 극복할 수 있다.

따라서, 신소재 개발 단계의 시간과 비용을 감축하고, 분석 한계를 극복함으로써 더 나아가 AI 기반의 최적 공정 조건 마련 단기화를 기대할 수 있다.

3-2. 향후 개선 사항



Figure 42. 프로젝트 향후 개선 사항

(1) 실제 측정치와의 비교를 통한 예측 정확도 향상

본 프로젝트의 최종 output인 소재 별 특성 예측 시, 대상 소재에 대한 분율 별 경도 데이터, 가공도 데이터 등을 기존 신소재 논문으로부터 발췌하여 구축하였으며, 회귀 분석을 통하여 데이터를 구체화하였다.

하지만, 실제 실험 환경에서 직접 관찰한 미세조직과 측정 데이터를 활용하여 Data를 생성한다면 논문에서 발췌한 데이터보다 신뢰도를 현격히 높일 수 있을 것으로 판단된다. 따라서, 모델 학습 및 시스템 구축 시 실제 측정치를 활용하여 특성치를 예측한다면 예측 정확도를 향상시킬 수 있을 것으로 기대된다.

(2) 양질의 데이터 수집을 통한 예측 오차 개선

본 프로젝트에서 사용된 데이터는 신소재 연구 단계에서 활용되는 소재 별 SEM(주사 전자 현미경) 촬영 사진으로 공개된 Dataset이 존재하지 않아 데이터 수집에 있어 어려움이 존재하였다. 따라서, 신소재 관련 논문에서 활용된 소재 별 미세조직 데이터를 발췌하였다. 발췌한 데이터에서 미세 조직에 해당되는 부분의 사진 데이터만 crop 하는 등의 전처리 과정을 거침에 따라 양질의 데이터 수집의 한계가 있었다. 또한, Ti64 등과 같이 한 시편에 대하여 여러 장의 단면 사진이 필요한 소재의 경우, 데이터 수집에 한계가 존재하였다. 따라서, 양질의 데이터 수집이 가능하면 예측 오차가 개선될 것으로 기대된다.

(3) 범용적인 소재 및 특성 종류로의 확대

본 프로젝트에서는 다양한 소재 종류 중 일부에 해당하는 DP steel, CFRP, Ti64 3가지 소재에 대하여 미세조직 분석 및 특성 예측하는 프로그램인 GANgineer를 개발하였다.

신소재 연구 및 개발 프로세스에서 미세조직 분석 및 특성 예측은 필수적인 과정 중 하나에 해당한다. 따라서, 신소재 연구 및 개발에 있어 시간 및 비용 단축을 통한 전반적인 기여를 위해서는 본 프로젝트의 산출물인 GANgineer 프로그램이 특정 소재에 국한되지 않고 범용적으로 사용되도록 확장해야 한다. 따라서, 범용적 확대를 위하여 소재 및 특성 종류의 범용적 확대를 통한 모델 학습이 필요하다.

(4) 목표 특성치 달성을 위한 공정 솔루션 제공 추가

신소재 개발은 사용 환경에 따른 application 별 요구되는 특성치 달성을 목표로 한다. 목표 특성치 달성을 위해서는 열처리 등과 같은 특정한 공정 솔루션이 필요하다. 따라서, 각 application 별 사용되는 소재의 목표 특성치 달성을 위한 공정 솔루션 제공을 추가함으로써 소재 개발 및 연구의 시간 및 비용 단축을 기대할 수 있다.

(5) Ti64 소재에 대한 최적 모델 탐색 필요

Ti64 소재를 제외한 다른 소재의 최적 모델은 GANomaly이며, 최적 모델에 대한 전체 오차 평균이 5% 이내인 것과 달리, Ti64의 경우 최적 모델이 Fast AnoGAN이며 전체 오차 평균이 10.37%로 높게 측정되었다.

Ti64의 오차가 높게 측정되는 원인은 다음과 같다. Ti64의 기공은 3D로 측정 시 정확하게 계산이 된다. 따라서, 논문의 기공도는 2D 이미지로 3차원인 기공도를 측정하기 위하여, 하나의 시편에 대하여 최소 50번 이상 단면의 기공도를 측정하여 평균을 낸 값을 기공도로 한다. 하지만, Test Dataset으로 활용한 Ti64의 사진의 경우, 하나의 2D 이미지로만 기공율을 측정하였다. 따라서, 시편 일부의 단면 기공율 특성치로 전체 기공율을 예측하였기 때문에 높은 오차가 측정되었다.

따라서, Ti64의 미세 조직 특징인 기공은 다른 소재들과 달리 3D 구조인 것이 중요하게 작용하므로 오차를 줄이기 위해서는 Ti64 소재에 대한 최적 모델 재 탐색이 필요하다.

4. 팀원 소개 및 상호평가



10기 최우수상을 받기까지

♥ 9주동안 수고 많았던 우리 조 ♥

To. 강연지

김은영 says

AI 프로젝트를 진행함에 있어, 프로젝트 주제의 Background 및 Insight에 대한 높은 이해도를 바탕으로 팀원들이 이해하기 쉽게 설명해주는 등 많은 노력을 하며 프로젝트 수행에 가장 큰 역할을 하였습니다.

오세현 says

팀의 연장자로서 많은 리더십을 발휘해 주었습니다. 특히 신소재 석사 출신이자 직장인 출신으로서 GANgineer 프로젝트에 큰 역할을 수행해 주셨습니다. 누나 고마웠어요!

우영빈 says

만언니로서 팀워크에 큰 역할을 해주었다. 프로젝트를 위해 힘쓴 것은 물론 사회생활의 선배로서 항상 팀을 좋은 방향으로 이끌어주었다. 신소재 공학도로서 AI 프로젝트에 가장 노력을 해준 팀원이다. 언니 덕분에 새로운 분야에 대해 심도 깊게 알게 되어서 보람 있는 시간을 보냈다.

이동현 says

AI 프로젝트 주제를 신소재로 잡은 만큼 석사로서의 면모를 확실히 보여줬고 이론적 배경이 탄탄했기에 프로젝트를 성공적으로 이끌었다고 생각한다. 항상 팀을 하나로 뭉치려고 하는 모습에서 조금 멋있었다.

이정하 says

톡톡 튀는 아이디어로 우리를 많이 웃게 해주었던 아이디어 बैं크를 담당한 팀원입니다. 그리고 조원들의 의견을 잘 수렴해 의사소통이 원활하지 않을 때 서로의 입장을 잘 조율해주는 만언니의 역할을 잘 해내주어서 항상 든든했습니다. 또한 연구와 실무 경력이 탄탄해 AI 프로젝트를 진행하면서 실무자의 입장에서 역할 수행에 대해 피드백 해주고 조언해주어서 많이 성장할 수 있었습니다.

To. 오세현

강연지 says

오세현 팀원은 팀장으로서 컴퓨터공학 전공자로서 배울 점이 많은 팀원이었습니다. 컴퓨터 관련 지식이 부족한 저를 항상 옆에서 자상하게 도와주는 짝이었을 뿐만 아니라 반 친구들과 항상 지식과 정보를 활발히 공유해 프로젝트의 질적 향상에 많은 기여를 하였습니다.

김은영 says

조장이자 컴퓨터 공학도로서 역할을 충실히 이행하였습니다. 특히 AI 프로젝트 GANgineer 모델링 구현 시, 프로젝트에 적합하게 각 모델에 대한 코드를 빠르게 구현함으로써 프로젝트가 빠르게 진행될 수 있었습니다.

우영빈 says

조장으로서 팀을 잘 이끌어나가려고 노력했다. 두 달간 팀을 위해 가장 노력한 팀원이라고 생각한다. 프로젝트 진행 시 맡은 역할도 많았고, 그것을 모두 완벽히 소화했다. 컴퓨터 공학도로서 많은 도움을 주었다.

이동현 says

외모적으로는 상남자답게 생겼지만 조장으로서 팀을 리드하는 모습은 굉장히 아름다웠다. 같은 컴퓨터 공학 전공이지만 굉장히 똑똑하였고 프로젝트를 진행하는데 있어서 항상 앞장서서 행동하고 프로젝트를 수행하였다.

이정하 says

자신의 실력과 지식을 다른 사람들에게 잘 나누고 공유하는 모습이 든든하고 보기 좋았던 팀원입니다. 경직될 수 있는 회의 분위기를 유하게 만들어 더 창의적이고 생산적이면서 재미도 있는 회의 시간을 만드는데 기여했다고 생각합니다. 조장으로서 팀원들을 항상 챙기고 뒤쳐지는 팀원이 없도록 항상 뒤에서 예의주시하고 있는 모습에서 조에 대한 책임감을 느낄 수 있었고, 많이 배웠습니다.

To. 김은영

강연지 says

김은영 팀원은 항상 성실하게 수업과 프로젝트에 임했을 뿐만 아니라, 여러 의견들을 잘 이해하고 타협점을 제시하여 팀 회의를 원만히 진행되게 애써주었습니다. 어느 것 하나 대충 넘기지 않고 끝까지 본인의 것으로 만드는 열정과 능력을 배우고 싶은 팀원입니다.

오세현 says

자칫 우리 팀에서 부족할 수 있었던 신중함을 채워주었습니다. 항상 많은 생각과 끊임없는 탐구로 프로젝트의 완성을 올려주는 역할을 수행해 주었습니다. 므농아 327 애껴 신어라!

우영빈 says

팀원 중 가장 신중하고 꼼꼼하여 항상 프로젝트의 올바른 방향을 제시해주는 꼭 필요한 팀원이었다. 또한 상대방이 기분 좋게 하는 말솜씨를 지녔고, 모두 지쳐있던 마지막까지 성실하였다. 본받을 점이 정말 많은 팀원이다.

이동현 says

그녀의 신중함... 때론 과하다 생각했지만 돌아해보면 꼭 필요한 존재였다. 놓치고 넘어갔을 부분들을 모두 캐치해내는 능력을 보면서 감탄했고 배울 점이 많은 사람이었다. 나에게 없는 신중함을 메꿔주었다.

이정하 says

무엇이든 급하게 판단하지 않고 신중하게 생각해 팀원 모두가 올바른 방향으로 잘 나아갈 수 있도록 도와준 팀원입니다. 자신만의 속도로 어떤 일이든 잘 해내는 것을 옆에서 지켜보면서 끈기와 근성을 닦고 싶다고 생각했습니다. 또, 팀원이 어려움을 겪고 있을 때 먼저 나서서 도와주는 따뜻한 마음을 가지고 있어 같은 팀원으로서, 그리고 옆자리 짝꿍으로서 항상 든든하고 고마웠습니다.

To. 우영빈

강연지 says

우영빈 팀원은 항상 밝은 에너지를 팀에 전달해주는 분위기 메이커였습니다. 또한 수학과 전공으로 다른 팀원들이 어려워하는 통계 부분 진도를 나갈 때 직접 자료를 제작하여 강의까지 해주는 성실하고 열정이 넘치는 팀원입니다. 프로젝트도 적극적으로 참여하여 많은 기여를 해주었습니다.

오세현 says

팀의 활기와 에너지를 맡아 두 달간 끊임없는 프로젝트 속에서 팀의 분위기를 이끌어 주었습니다. 또 수학과로서의 지식과 통찰력은 프로젝트의 위기 때 마다 팀을 구원해 주었습니다. 영빈아 너 덕에 우리가 10기 최우수팀이 됐다고 생각해. 고마워!

김은영 says

항상 팀원들에게 팀 프로젝트에서 현재 부족한 사항이 무엇인지 확인하며, 부족한 부분을 빠르게 채워 나갈 수 있도록 도와주었습니다. 또한, 항상 밝은 웃음으로 팀 분위기를 밝게 채워주었습니다.

이동현 says

항상 자기를 낮추면서 남을 띄워주는 역할이었다. 때론 자기 의견이 없는 것 같아 보여 답답했지만 뒤로 갈수록 자기 의견을 내비추면서 팀원들의 분위기를 잘 이끌어 나간 주역이었다고 생각한다. 그리고 처음보다 실력이 가장 향상되었다고 생각하는 팀원이다.

이정하 says

항상 배우려고 하는 모습, 밝고 긍정적인 기운, 그리고 늘 성실한 모습과 체력 등 본받고 싶은 점이 많은 팀원입니다. 특히 회의 시간에 자신의 의견을 논리적으로 주장하는 모습을 보며 항상 적극적으로 참여하려고 하는 것이 보기 좋았습니다. 그리고 이해가 되지 않는 부분을 차분하게, 그리고 차근차근히 설명해주는 모습은 저에게 없는 부분이기에 더욱 본받고 싶다고 생각했습니다.

To. 이동현

강연지 says

이동현 팀원은 프로그래밍 관련 프로젝트 경험들로 저희 팀 프로젝트를 진행하는데 상당 부분 기여했으며, 항상 앞장 서서 동기부여를 해주었으며, 덕분에 저희 조가 나태해지거나 좌절할 틈 없이 순탄하게 프로젝트를 마무리할 수 있었습니다.

오세현 says

저 혼자만으로는 부족할 수 있었던 컴퓨터 공학적 시각을 채워주고 강인한 결단력과 수행으로 프로젝트의 원활한 진행을 지원해주었습니다. 동현아 카카오 취직하면 밥 한끼 사줘라!

김은영 says

프로젝트 관련 토의 시, 컴퓨터 공학 전공자로서 전공자 측면에서 프로젝트의 수행 가능성 등을 판단해주어 기간 내에 프로젝트가 잘 마무리될 수 있었습니다. 또한, 모델링 결과를 잘 표현할 수 있도록 시스템을 빠른 시간 내에 구축해주었습니다.

우영빈 says

화끈한 성격으로 모든 결정을 빨리 하는 특징을 지닌 팀원이다. 이동현 팀원 덕분에 일이 빠르게 진행되었고 완성도는 높았다. 성격이 화끈하여 대하기 가장 편한 팀원이다. 2 개월동안 짝으로서 많이 도와주었고 가르쳐주어서 감사하다.

이정하 says

결단력이 빠르고 상황 판단에 대한 정확도도 높아서 같이 일하기 편하고 좋았던 팀원입니다. 그리고 자신이 잘하는 것을 알고 있고 그것을 팀 프로젝트에서 잘 수행해주어서 고마웠습니다. 또, 무심한듯하면서 팀원들을 챙기는 모습이 보기 좋았고, 회의 때마다 특유의 결단력을 발휘해 모두가 빠르고 정확하게 판단할 수 있게 도와주어 효율적으로 프로젝트를 진행하는데 도움이 많이 되었습니다.

To. 이정하

강연지 says

이정하 팀원은 항상 에너지가 넘치고 새로운 지식을 배우는 데에 열의가 강한 팀원입니다. 덕분에 팀회의가 원만하고 빠르게 진행될 수 있었습니다. 프로젝트 발표를 맡았는데 소재 개발은 처음 공부한 분야임에도 열심히 도메인 지식을 습득한 덕택에 성공적으로 발표를 마칠 수 있었습니다.

오세현 says

비전공자이지만 배움에 대한 끝없는 열정으로 팀의 면학 분위기를 조성한 어른스러운 친구입니다. 하지만 나이에 서 묻어나는 귀여움은 어쩔 수가 없나 봅니다. 정하야 전공자로서 너의 학문에 대한 열정은 정말 존경하고 있어! 비록 비전공자에 가려는 길이 험할 수 있겠지만 항상 응원하고 도움 줄 수 있는 건 기꺼이 도와 줄게! 항상 힘내! 아자아자~ 하이딩~!!

김은영 says

발표자로서 프로젝트의 전반적인 내용을 이해하고, 프로젝트의 부족한 부분을 채우려고 노력하였습니다. 또한, 회의 시 항상 깔끔하게 내용을 정리하여 이후 팀원들이 되새길 수 있도록 도와주었습니다.

우영빈 says

막내지만 '언니'라고 부르고 싶을 정도로 어른스러운 팀원이었다. 교육학과로서 말을 굉장히 잘하고, 일을 확실하게 처리했다. 가끔 보이는 귀여운 모습은 팀원들에게 활력이 되었다. 마지막 AI 발표를 할 때, 비전공자임에도 불구하고 신소재 공학의 이론과 컴퓨터 공학의 내용들을 모두 이해하려 노력하는 모습이 가장 인상 깊었고, 존경스러웠다.

이동현 says

우리 어른스러운 막내. 자신의 역할을 항상 성실히 수행하는 모습을 보면 동생이지만 배울 점이 많았고 마지막 발표에서 팀원들의 노력을 배신하지 않고 열심히 발표 준비를 하고 성공적으로 발표를 해내는 모습이 정말 보기 좋았다.

5. Reference

1. Advanced Steel microstructural classification by deep learning methods, 2020
2. Pores for thought: generative adversarial networks for stochastic reconstruction of 3D multi-phase electrode microstructures with periodic boundaries, 2020
3. Structural Material Property Tailoring Using Deep Neural Networks, 2019
4. Automatic defects detection in CFRP thermograms, using convolutional neural networks and transfer learning, 2019
5. Experimental and numerical study on geometrically necessary dislocations and non-homogeneous mechanical properties of the ferrite phase in dual phase steels, Acta Mater, 2011
6. Advanced Steel Microstructural Classification by Deep Learning Methods, nature, 2017
7. Dual-phase steels microstructure and properties consideration based on artificial intelligence techniques, 2014
8. New model of CFRP-confined circular concrete columns: ANN approach, 2013
9. f-AnoGAN: Fast unsupervised anomaly detection with generative adversarial networks, Medical Image Analysis, 2019
10. Decision Boundary-Based Anomaly Detection Model Using Improved AnoGAN From ECG Data, IEEE, 2020
11. Bone Metastatic Tumor Detection based on AnoGAN Using CT Images, IEEE, 2019
12. GANomaly: Semi-supervised Anomaly Detection via Adversarial Training, ACCV, 2019
13. Artificial neural network application to study quantitative relationship between silicide and fracture toughness of Nb-Si alloys, Materials&Design, 2017
14. Numerical simulation and designing artificial neural network for estimating melt pool geometry and temperature distribution in laser welding of Ti6Al4V alloy, Optik, 2016